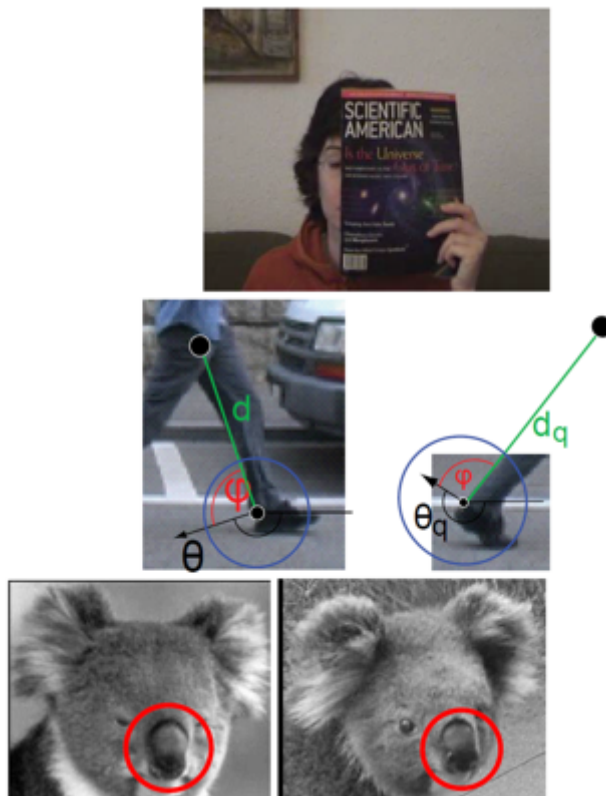


局部特征

- 全局特征会面临难以克服的困难
 - 遮挡，形变，环境



特征检测

目标：


- 稳定检测（如果两次检测出的特征点差别很大，无法进行匹配）



No chance to match!

We need a repeatable detector!

- 易于匹配



挑战

- 对图像几何变换的稳定性
- 对颜色，光照变化的稳定性


需求

- 区域提取需要是可重复的和准确的
 - 不受平移，旋转，大小的影响
 - 不受仿射变换的影响
 - 对光照变化、噪音、模糊、量有很好的适应性
- 局部性：特征是局部的，应该对遮挡和杂乱具有鲁棒性
- 数量：需要足够数量的区域来覆盖该物体
- 区别性：这些区域应该包含有趣的结构
- 效率：接近实时


角点检测

角点的概念


- 平坦区域：各方向都没有变化
- 边：单方向有变化
- 角点：各方向都有变化



“flat” region:
no change in all
directions



“edge”:
no change along
the edge direction



“corner”:
significant change
in all directions



Harris角点检测

在角点处，沿任意方向运动都会引起像素颜色的明显变化

等价于：在角点附近，图像梯度具有至少两个主方向

- 数学模型：若窗口发生小位移移动 u, v ，计算窗口内像素变化
 - $w(x, y)$ 是权重，可以设置窗口内所有位置的权重都为1，也可以利用高斯函数（角点中心的点的贡献更大）
 - $I(x + u, y + v)$ 为位置 x, y 移动后位置的像素值
 - $I(x, y)$ 为位置 x, y 位置的像素值

$$E(u, v) = \sum_{x, y} w(x, y) [I(x + u, y + v) - I(x, y)]^2$$



- 将上式进行泰勒展开，可以得到如下形式

$$E(u, v) \approx [u \ v] M \begin{bmatrix} u \\ v \end{bmatrix}$$

M 是一个 2×2 的矩阵，元素是图像梯度

- I_x 是 x 方向的梯度
- I_y 是 y 方向的梯度

$$M = \sum_{x, y} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

Sum over image region - the area we are checking for corner

Gradient with respect to x , times gradient with respect to y

$$M = \begin{bmatrix} \sum I_x I_x & \sum I_x I_y \\ \sum I_x I_y & \sum I_y I_y \end{bmatrix} = \sum \begin{bmatrix} I_x \\ I_y \end{bmatrix} [I_x \ I_y]$$

- 若角点是与坐标轴对齐的，则每个点的梯度是与 x 轴平行或与 y 轴平行的。

如果两个 λ 都接近 0，则不是角点。角点位置的两个 λ 应该都比较大


$$M = \begin{bmatrix} \sum I_x^2 & \sum I_x I_y \\ \sum I_x I_y & \sum I_y^2 \end{bmatrix} = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix}$$

- 若角点不与坐标轴对齐， M 是对称的，可分解如下（对称矩阵的性质）


Since M is symmetric, we have $M = R^{-1} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} R$
(Eigenvalue decomposition)

我们可以把 M 想象成一个椭圆，其轴线长度由特征值决定，方向由 R 决定。可以把 R 看成旋转因子，其不影响两个正交方向的变化分量。经对角化处理后，将两个正交方向的变化分量提取出来，就是 λ_1 和 λ_2 （特征值）。

为什么可以想象成椭圆：【特征检测】Harris角点检测中的数学推导 [hujingshuang-CSDN博客](#)



当 λ_1 和 λ_2 都比较大，并且差不多大时，是角点




因为特征值计算起来比较麻烦，所以我们定义了响应函数

$$R = \det(M) - \alpha \text{trace}(M)^2 = \lambda_1 \lambda_2 - \alpha (\lambda_1 + \lambda_2)^2$$

角点的 $|R|$ 大，平坦区域 $|R|$ 小，边缘的 $|R|$ 为负值

- **Fast approximation**
 - Avoid computing the eigenvalues
 - α : constant (0.04 to 0.06)




光照，几何不变性？

具有旋转不变性和光照不变性，不具有尺度不变性

- 旋转不变性

对于下图，我们用椭圆表示 M 。图像旋转后，椭圆旋转了，但是形状没变，因此响应函数 R 没变



- 不具有尺度不变性：尺度变化会将角点变成边缘
- 加法变化不变性（整体光照）：使用的是梯度

斑点检测

利用图像的 *Hessian* 矩阵。想法：在两个正交方向上寻找强梯度。全是二阶导

使用公式 $\det(H)$ ，认为 $\det(H)$ 大的是角点


$$\det(H) = I_{xx}I_{yy} - I_{xy}^2 = \lambda_1\lambda_2$$

结果：响应主要在角点处和纹理比较强的区域，但是我们想要检测的是斑点

二阶导关注的是图像像素急剧变化的区域，同样对噪声比较敏感

$$H = \begin{pmatrix} \frac{\partial^2 I}{\partial^2 x^2} & \frac{\partial^2 I}{\partial x \partial y} \\ \frac{\partial^2 I}{\partial y \partial x} & \frac{\partial^2 I}{\partial^2 y^2} \end{pmatrix}$$

$$H = R^{-1} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} R$$



Hessian对光照变化和几何变换的稳定性?

如何实现尺度不变

我们观察物体时，若物体离得近，则看起来又大又清晰。若离得远，则看起来又小又模糊。

进行特征检测时，计算机并不能判断图像中物体的尺度，因此我们使用金字塔来建立一系列不同尺度的图像集

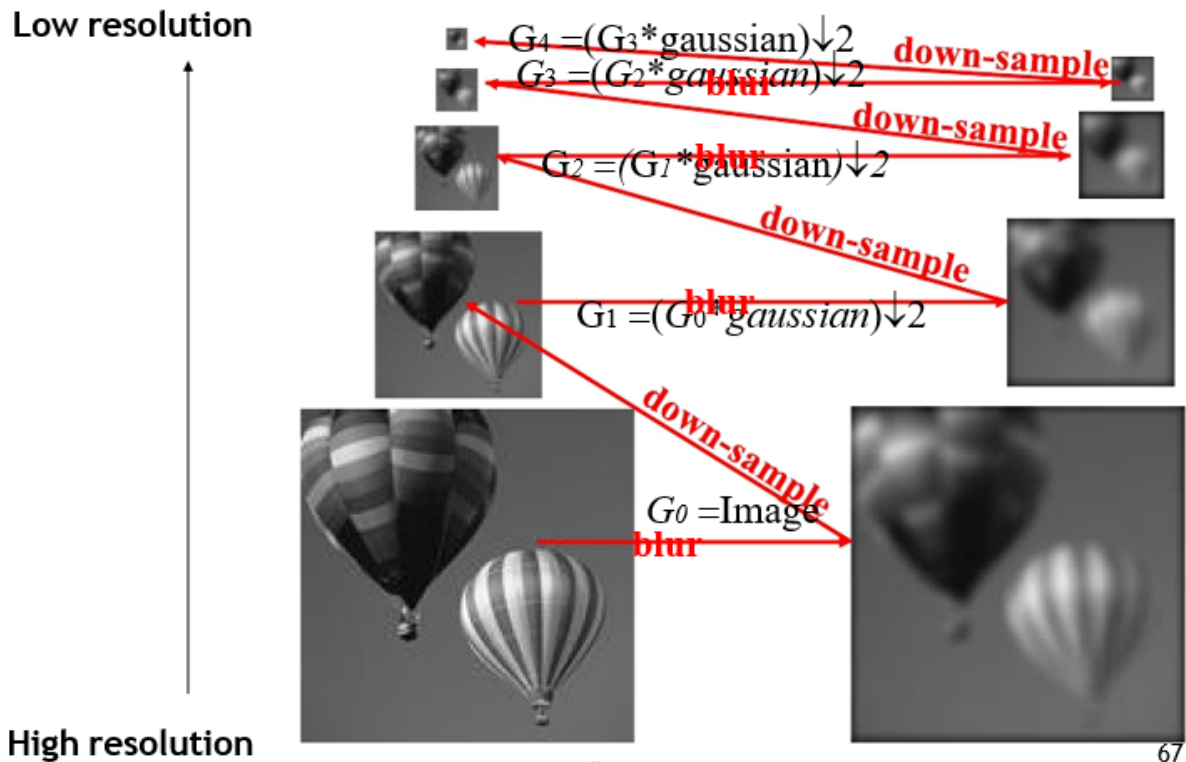
图像的尺度空间是指图像的模糊程度，而非图像的大小。近距离看一个物体和远距离看一个物体，模糊程度是不一样的；从近到远，图像越来越模糊的过程，也是图像的尺度越来越大的过程。

高斯金字塔

高斯核是实现尺度变换的唯一变换核

通过降采样构建高斯金字塔。降采样前需要先对图像进行平滑以避免伪影（信号学知识）

The Gaussian Pyramid

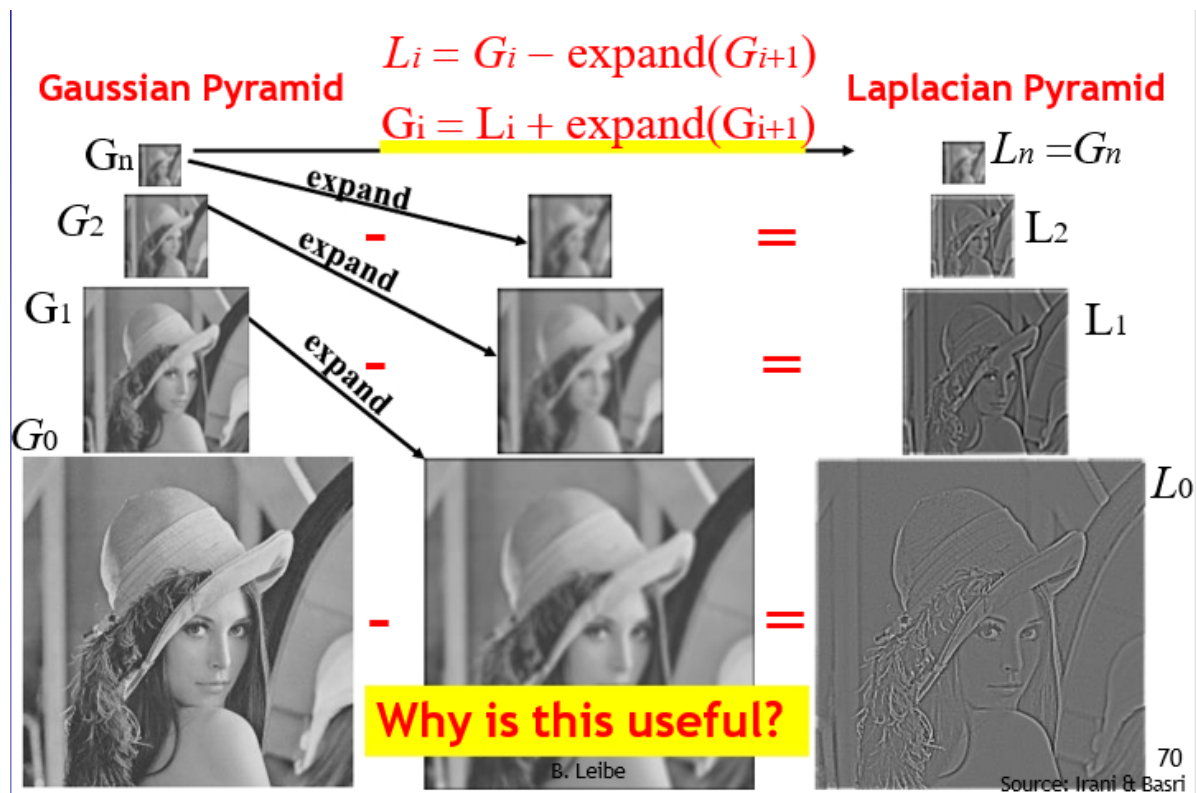


- 构建：每一层都通过对前一层进行平滑和下采样来得到
- 为什么使用高斯？部分原因：
 - 高斯 * 高斯 = 另一个高斯
 - $G(\sigma_1) * G(\sigma_2) = G(\text{sqrt}(\sigma_1^2 + \sigma_2^2))$
- 高斯滤波是低通滤波，当对图像模糊后，图像中的某些信息进行融合，这些信息中是有冗余信息的，因此没有必要以完整的原始分辨率来存储平滑的图像。也就是说，我们可以降采样以减少存储空间

拉普拉斯金字塔

通过用大图减去升采样(插值 + 滤波)后的小图得到。实际上进行的是 DOG 的过程（高斯的差分）

- 升采样后的图和原图大小一致，但更模糊，相当于对原图进行滤波得到的。因此两图相减是高斯的差分



- 拉普拉斯图像分解和重建
- 拉普拉斯图像融合

实现尺度不变

在不同尺度同时进行检测与匹配

暴力


利用多个size的检测框对图像进行扫描

缺点：

- 计算效率低下
- 效率低下，但可用于匹配
- 对大型数据库的检索来说是不可能的
- 不利于识别

- Comparing descriptors while varying the patch size

- Computationally inefficient
- Inefficient but possible for matching
- Prohibitive for retrieval in large databases
- Prohibitive for recognition



自动尺寸选择

思想：针对检测区域设计一个尺度不变的函数（不管尺寸是怎样的，只要包含的内容一样，值就一样）

方法：


- 取函数的局部最大值



为什么我们这里要找最大值呢？

原因：进行特征检测时，我们往往定义一个指标，并判断这个指标最大值对应的区域为特征点

- 最大值对应的区域对图像尺寸来说是不变的

图像尺寸变为 $1/2$ ，则最大响应值对应的区域大小也是 $1/2$






归一化：区域大小变换到固定的尺寸

什么样的函数是有效的呢？

LOG：LOG的不同 σ 影响着其检测框的scale。 σ 越大，scale越大（因此可以使用不同 σ 的 LOG 来进行不同尺寸的特征检测）

- Laplacian-of-Gaussian = “blob” detector



我们记录 interest points：LOG尺度空间上的局部最大值对应的位置

实际使用时，我们常使用DOG来近似代替LOG，因为这样更方便计算


- We can efficiently approximate the Laplacian with a difference of Gaussians:

$$L = \sigma^2 (G_{xx}(x, y, \sigma) + G_{yy}(x, y, \sigma))$$

(Laplacian)

$$DoG = G(x, y, k\sigma) - G(x, y, \sigma)$$

(Difference of Gaussians)



- 流程
 - 在尺度空间上检测 DOG 的局部最大值
 - 非极大值抑制
 - 消除边缘响应 (由于某些原因, 在检测极值点时, 边缘容易被检测出来)